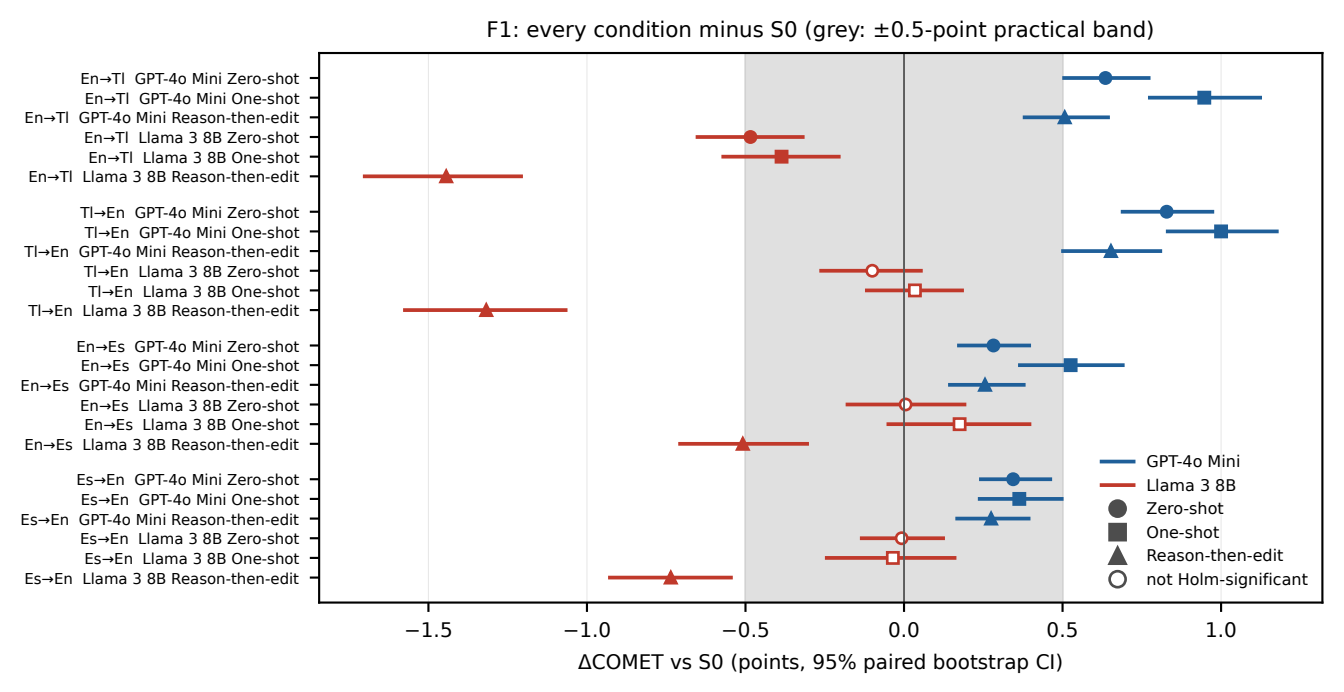
F1: every condition minus S0 (grey: ±0.5-point practical band)
En→Tl GPT-4o Mini Zero-shot
En→Tl GPT-4o Mini One-shot
En→Tl GPT-4o Mini Reason-then-edit
En→Tl Llama 3 8B Zero-shot
En→Tl Llama 3 8B One-shot
En→Tl Llama 3 8B Reason-then-edit
Tl→En GPT-4o Mini Zero-shot
Tl→En GPT-4o Mini One-shot
Tl→En GPT-4o Mini Reason-then-edit
Tl→En Llama 3 8B Zero-shot
Tl→En Llama 3 8B One-shot
Tl→En Llama 3 8B Reason-then-edit
En→Es GPT-4o Mini Zero-shot
En→Es GPT-4o Mini One-shot
En→Es GPT-4o Mini Reason-then-edit
En→Es Llama 3 8B Zero-shot
En→Es Llama 3 8B One-shot
En→Es Llama 3 8B Reason-then-edit
Es→En GPT-4o Mini Zero-shot
Es→En GPT-4o Mini One-shot
Es→En GPT-4o Mini Reason-then-edit
Es→En Llama 3 8B Zero-shot
Es→En Llama 3 8B One-shot
Es→En Llama 3 8B Reason-then-edit
GPT-4o Mini
Llama 3 8B
Zero-shot
One-shot
Reason-then-edit
not Holm-significant
−1.5
−1.0
−0.5
0.0
0.5
1.0
ΔCOMET vs S0 (points, 95% paired bootstrap CI)